

Trabalho Prático: Agente Inteligente em Labirinto

Luccas Vinicius - 20.1.8015

2026

1 Introdução

Este trabalho apresenta a implementação de um agente inteligente capaz de atuar em um labirinto discreto representado por uma matriz. O domínio foi utilizado para avaliar três abordagens de resolução de problemas em Inteligência Artificial: busca clássica, busca local e busca online.

O objetivo principal foi construir uma solução simples, funcional e explicável, permitindo comparar algoritmos, coletar métricas e analisar o comportamento do agente em diferentes condições de conhecimento do ambiente.

2 Modelagem PEAS

A modelagem PEAS descreve o agente em termos de desempenho, ambiente, atuadores e sensores.

2.1 Performance

A medida de desempenho considera que o agente deve encontrar soluções com baixo custo, menor quantidade de passos, menor número de nós expandidos e menor tempo de execução. De forma geral, o desempenho pode ser representado por:

$$J = -\alpha \cdot \text{custo} - \beta \cdot \text{expandidos} - \gamma \cdot \text{tempo} - \delta \cdot \text{revisitadas}$$

Quanto menor o custo, o tempo e o número de expansões, melhor é o comportamento do agente.

2.2 Environment

O ambiente é um labirinto em grade bidimensional. Cada célula pode representar parede, espaço livre, posição inicial, objetivo final ou ponto de coleta obrigatório. No modo online, parte do ambiente inicia desconhecida.

2.3 Actuators

O agente executa movimentos ortogonais:

$$A = \{\text{cima}, \text{baixo}, \text{esquerda}, \text{direita}\}$$

2.4 Sensors

Na busca clássica, o agente conhece o mapa completo. Na busca online, o agente percebe apenas uma vizinhança local e atualiza progressivamente seu mapa interno.

3 Classificação Do Agente

O agente implementado é baseado em objetivos e utiliza modelo interno. Ele é baseado em objetivos porque suas ações são escolhidas para alcançar o objetivo final. Ele utiliza modelo interno porque mantém uma representação do labirinto e, no modo online, atualiza essa representação conforme novas células são percebidas.

O agente também pode ser analisado como parcialmente baseado em utilidade, pois compara soluções por custo, tempo, nós expandidos e qualidade do caminho.

4 Formulação Formal

O problema de busca clássica foi formulado como:

$$\langle S, A, T, s_0, G, c \rangle$$

onde:

- S é o conjunto de posições livres do labirinto;
- A é o conjunto de ações possíveis;
- T é a função de transição entre estados;
- s_0 é a posição inicial do agente;
- G é o teste de objetivo;
- c é o custo de cada movimento.

Na busca local, a solução candidata é uma permutação dos pontos de coleta. O custo total da solução é a soma dos menores caminhos entre a origem, os pontos de coleta e o objetivo final.

5 Algoritmos Implementados

5.1 Busca Em Largura

A BFS explora os nós por nível. Como todos os movimentos possuem custo unitário, ela encontra o menor caminho em número de passos.

5.2 Busca Em Profundidade

A DFS explora um caminho até o fim antes de retroceder. Ela pode encontrar solução rapidamente, mas não garante caminho ótimo.

5.3 Busca De Custo Uniforme

A UCS expande primeiro o nó de menor custo acumulado. Quando todos os custos são iguais, seu comportamento tende a ser semelhante ao da BFS.

5.4 Busca Gulosa

A busca gulosa utiliza apenas a heurística de distância de Manhattan até o objetivo. Ela costuma ser rápida, mas não garante solução ótima.

5.5 A Estrela

O A* utiliza a soma do custo acumulado com a heurística:

$$f(n) = g(n) + h(n)$$

A heurística utilizada foi a distância de Manhattan:

$$h(n) = |x_n - x_B| + |y_n - y_B|$$

Essa heurística é admissível para labirintos com movimentos ortogonais e custo unitário, pois nunca superestima o custo real mínimo até o objetivo.

6 Busca Local

Na etapa de busca local, o agente deve visitar todos os pontos de coleta antes de alcançar o objetivo. A solução é representada pela ordem de visita dos pontos C .

Foram implementados Hill-Climbing e Simulated Annealing. A vizinhança utilizada foi a troca de posição entre dois pontos de coleta. Essa escolha foi adotada por ser simples, fácil de implementar e adequada para modificar a ordem de visita.

6.1 Hill-Climbing

O Hill-Climbing avalia vizinhos da solução atual e aceita apenas movimentos que reduzem o custo. Sua limitação principal é a possibilidade de ficar preso em mínimos locais.

6.2 Simulated Annealing

O Simulated Annealing permite aceitar soluções piores em alguns momentos, principalmente no início da execução, reduzindo a chance de ficar preso em mínimos locais. A temperatura inicial e a taxa de resfriamento influenciam diretamente a exploração.

7 Busca Online

Na busca online, o agente não conhece o mapa completo inicialmente. Foi implementada a estratégia de replanning com A*. O ciclo seguido pelo agente é:

$$\textit{perceber} \rightarrow \textit{atualizar mapa interno} \rightarrow \textit{planejar} \rightarrow \textit{agir}$$

A cada passo, o agente percebe a vizinhança local, atualiza seu mapa interno e executa A* novamente sobre o mapa parcialmente conhecido. O agente executa apenas o próximo movimento planejado e repete o processo.

8 Metodologia Experimental

Os algoritmos foram executados sobre um mapa textual contendo paredes, células livres, posição inicial, objetivo final e pontos de coleta. As métricas coletadas foram exportadas em arquivos CSV.

Para busca clássica, foram analisados sucesso, custo, passos, nós explorados, nós expandidos, tempo de execução e tamanho máximo da fronteira.

Para busca local, foram analisados melhor custo, pior custo, custo médio, tempo médio, número médio de iterações e taxa de sucesso.

Para busca online, foram analisados movimentos, custo real, células reveladas, células revisitadas, replanejamentos e razão entre custo online e custo ótimo offline.

9 Resultados

Os resultados foram gerados automaticamente na pasta **results/**. A Tabela 1 apresenta o formato utilizado para comparação dos algoritmos clássicos.

Tabela 1: Métricas da busca clássica

Algoritmo	Sucesso	Custo	Passos	Expandidos	Tempo	Fronteira
BFS	Sim	-	-	-	-	-
DFS	Sim	-	-	-	-	-
UCS	Sim	-	-	-	-	-
Gulosa	Sim	-	-	-	-	-
A*	Sim	-	-	-	-	-

Os valores concretos podem ser consultados nos arquivos CSV gerados pela execução do programa.


`../results/graficos/caminho_astar.png`

Figura 1: Caminho encontrado pelo algoritmo A*.



`../results/graficos/convergencia_hill_climbing.png`

Figura 2: Curva de convergência do Hill-Climbing.



`../results/graficos/convergencia_simulated_annealing.png`

Figura 3: Curva de convergência do Simulated Annealing.

10 Análise Crítica

A BFS encontrou o menor caminho quando todos os movimentos tinham custo unitário, pois explora os estados por profundidade crescente. A DFS encontrou solução, mas não garante qualidade, pois pode seguir caminhos longos antes de testar alternativas melhores.

A UCS não apresentou grande diferença em relação à BFS quando todos os custos eram iguais. Caso os custos variassem, a UCS seria mais adequada, pois priorizaria o menor custo acumulado.

A busca gulosa foi eficiente, mas não é ótima, pois considera apenas a proximidade heurística do objetivo. Já o A* apresentou melhor equilíbrio entre qualidade da solução e eficiência, pois combina custo acumulado e heurística.

Na busca local, o Hill-Climbing pode ficar preso em mínimo local, pois aceita apenas melhorias. O Simulated Annealing tende a ser mais robusto porque aceita soluções piores de forma controlada, principalmente no início da execução.

Na busca online, o agente pode tomar decisões subótimas porque não conhece o mapa completo. A razão online/offline mede o custo pago pela falta de conhecimento inicial do

ambiente.

11 Limitações

A solução utiliza mapas pequenos e custo unitário de movimento. A visualização é simples, baseada em imagens estáticas. A busca online utiliza uma estratégia básica de replanning e pode ser melhorada com técnicas mais sofisticadas de exploração de fronteiras.

12 Uso De IA

Foi utilizada IA generativa como ferramenta de apoio para estruturar o código, revisar conceitos e auxiliar na documentação. O uso foi registrado no arquivo `uso_ia.md`. A solução foi validada por execução prática e geração de métricas.

13 Conclusão

O trabalho permitiu comparar diferentes estratégias de busca em um mesmo domínio. A busca clássica foi adequada quando o mapa era conhecido. A busca local foi utilizada para otimizar a ordem dos pontos de coleta. A busca online demonstrou o impacto da falta de conhecimento inicial do ambiente, exigindo percepção, atualização do modelo interno e replanejamento contínuo.